

Classificação de Risco Cardíaco com ANFIS: Comparação entre Sistemas Neuro-Fuzzy e MLP com Foco em Interpretabilidade

Victor M. Bertini

*Faculdade de Engenharia Elétrica e de Computação (FEEC) — Universidade Estadual de Campinas (Unicamp)
Campinas, SP, Brasil · RA 194761 · v194761@dac.unicamp.com.br*

Resumo—Este trabalho investiga o tradeoff entre acurácia preditiva e interpretabilidade em modelos de aprendizado de máquina para classificação de risco de doença cardíaca. Propomos um sistema ANFIS (Adaptive Neuro-Fuzzy Inference System) de Takagi-Sugeno com fuzzificação mista—funções Gaussianas para variáveis numéricas e codificação one-hot suavizada para variáveis categóricas—cujo pool de regras é gerado por agrupamento K-Means. Experimentos no Heart Failure Prediction Dataset (918 pacientes, 11 features) mostram que o ANFIS atinge AUC-ROC 0,912, acurácia 84,2% e F1-Score 85,9%, superando o MLP baseline (AUC 0,901; acurácia 81,5%; F1 82,5%) com apenas 228 parâmetros treináveis frente a 2.881 do MLP. O ANFIS produz ainda 10 regras linguísticas SE-ENTÃO auditáveis alinhadas à literatura sobre isquemia.

Palavras-chave—ANFIS; Lógica Fuzzy; Redes Neurais; Doença Cardíaca; Interpretabilidade; Takagi-Sugeno; K-Means

I. INTRODUÇÃO

Sistemas de apoio a decisão clínica baseados em aprendizado de máquina atingem alta acurácia em tarefas de diagnóstico, porém frequentemente operam como caixas-pretas, fornecendo previsões sem justificativa inteligível [1]. No contexto médico, a rastreabilidade das decisões é tanto um requisito ético quanto regulatório.

Sistemas Neuro-Fuzzy—em particular o ANFIS—combinam a capacidade de aprendizado de redes neurais com a interpretabilidade de sistemas de inferência fuzzy [2]. Regras do tipo SE *antecedente* ENTÃO *consequente* permitem que clínicos e auditores inspecionem os critérios decisórios sem expertise em aprendizado de máquina.

Este trabalho apresenta: (i) arquitetura ANFIS com fuzzificação mista para features numéricas e categóricas; (ii) método de geração de pool de regras por K-Means escalável para múltiplas variáveis categóricas; e (iii) comparação quantitativa com MLP no Heart Failure Prediction Dataset [3], demonstrando que o ANFIS supera o MLP com 13× menos parâmetros.

II. DATASET E PRÉ-PROCESSAMENTO

A. Heart Failure Prediction Dataset

O dataset combina registros de cinco fontes clínicas, totalizando 918 pacientes adultos. A variável alvo **HeartDisease** é binária (0=saudável, 1=doença) com ~55% de positivos. Split 80/20 com estratificação por classe.

As 11 features compreendem 5 numéricas e 6 categóricas (Tabela I).

Feature	Tipo	Descrição
Age	Numérica	Idade do paciente (anos)
RestingBP	Numérica	Pressão arterial em repouso (mmHg); zeros → mediana
Cholesterol	Numérica	Colesterol sérico (mg/dL); zeros → mediana
MaxHR	Numérica	Frequência cardíaca máxima atingida (bpm)
Oldpeak	Numérica	Depressão do segmento ST por exercício (mm)
Sex	Categórica	M / F
ChestPainType	Categórica	ATA / NAP / ASY / TA
FastingBS	Categórica	Glicemia em jejum > 120 mg/dL: 1=sim, 0=não
RestingECG	Categórica	Normal / ST / LVH
ExerciseAngina	Categórica	Angina por exercício: Y / N
ST_Slope	Categórica	Inclinação do ST: Up / Flat / Down

TABELA I. Features do dataset.

B. Pré-Processamento

Valores zerados em **RestingBP** e **Cholesterol** são substituídos pela mediana das entradas não-nulas. Features categóricas são codificadas como inteiros via *pd.Categorical.codes*. A normalização usa um **PartialScaler** customizado: z-score somente nas 5 features numéricas, preservando os códigos inteiros das categóricas—essencial para que *MixedFuzzyLayer* faça o cast correto dos índices categóricos.

III. ARQUITETURA ANFIS

O modelo ANFIS segue o paradigma Takagi-Sugeno de ordem zero com três camadas treináveis encadeadas. O fluxo de dados é:

$$X [B,11] \rightarrow \text{MixedFuzzyLayer} \rightarrow [B,11,M] \rightarrow \text{ClusterRuleLayer} \rightarrow [B,R] \rightarrow \text{DefuzzyLayer} \rightarrow [B,1] \rightarrow \text{sigmoid} \rightarrow P(\text{doença})$$

onde B é o batch size, M o número de MFs por feature numérica e R o número de regras no pool.

A. MixedFuzzyLayer

Features numéricas — MFs Gaussianas treináveis com centro c e dispersão s, otimizados por retropropagação:

$$\mu(x) = \exp(-0,5 * ((x - c) / s)^2)$$

Dispersões são clampedas em $s \geq 1e-6$ e inicializadas como $s = |N(0,1)| + 0,1$ para garantir positividade.

Features categóricas — codificação one-hot suavizada, sem parâmetros treináveis. Para uma variável com n categorias:

$$\mu_j(cat) = 0,95 \text{ se } j = cat, \text{ caso contrário } 0,05 / (n - 1)$$

Fornece gradiente não-nulo às posições não-correspondentes, evitando colapso de regras no treinamento.

B. ClusterRuleLayer

A força de disparo da regra k é a T-norma produto sobre todas as features:

$$w_k = \text{produto}_i \mu_{\{i, \text{combo}[k,i]\}}(x_i)$$

onde $\text{combo}[k,i]$ é o índice da MF da regra k na feature i . A tabela de combinações é armazenada como `register_buffer` (migração automática para GPU). Sem parâmetros treináveis.

C. DefuzzyLayer

Defuzzificação Takagi-Sugeno normalizada:

$$w_k = w_k / (\text{soma}_j w_j + \text{eps})$$

$$y_{\text{hat}} = \text{soma}_k w_k * c_k$$

Os consequentes c_k são pesos de `nn.Linear(R→1)`. A normalização mantém a escala da saída independente do número de regras que disparam simultaneamente, preservando a interpretação linguística de c_k .

D. Função de Perda

A função de perda combina entropia cruzada binária com penalidade de separação:

$$L = \text{BCE}(\text{sigma}(y_{\text{hat}}), y) + \text{lambda} * \text{soma}_{\{i < j\}} \text{relu}(s_i + s_j - |c_i - c_j|)$$

A penalidade ($\text{lambda}=0,1$) é zero quando centros adjacentes estão afastados por pelo menos $s_i + s_j$, e cresce linearmente caso contrário, impedindo que uma MF estreita fique contida dentro de outra mais larga.

IV. GERAÇÃO DO POOL DE REGRAS VIA K-MEANS

O número de combinações de antecedentes cresce exponencialmente: $n_{\text{regras}} = M^{n_{\text{features}}}$. Para 11 features com $M=3$ seriam 177.147 regras—inviável. O pipeline a seguir gera um pool gerenciável antes do treino:

Passo 1 — Picos percentílicos (artifício de mapeamento): Para cada feature numérica, n_{mfs} percentis uniformes da distribuição de treino (P25, P50, P75 para $M=3$) servem de picos de MFs triangulares

auxiliares para o mapeamento cluster→índice. NÃO são as MFs Gaussianas do ANFIS.

Passo 2 — K-Means: 200 clusters no espaço de features identificam as regiões de maior densidade.

Passo 3 — Mapeamento dominante: Para cada centro de cluster, determina-se o índice de MF dominante: numérica → argmax da MF triangular; categórica → $\text{round}(\text{centro})$ → código inteiro.

Passo 4 — Deduplicação: Clusters com o mesmo vetor dominante colapsam em uma regra. 200 clusters → 197 combos únicos nesta execução.

Passo 5 — Inicialização: Centros Gaussianos do ANFIS são inicializados nos percentis dos centros K-Means por feature.

V. CONFIGURAÇÃO EXPERIMENTAL

Os hiperparâmetros estão na Tabela II. Ambos os modelos usam otimizador Adam com scheduler de plateau e early stopping com paciência de 20 épocas.

Parâmetro	ANFIS	MLP
Épocas	200	200
Batch size	32	32
Learning rate	1e-3	1e-3
Arquitetura	3 MFs, 197 regras	[64, 32]
Parâmetros	228	2.881
Regularização	Sep. penalty $\lambda=0,1$	—
Semente	42	42

TABELA II. Hiperparâmetros experimentais.

Métricas avaliadas no conjunto de teste (20%): AUC-ROC (independente de limiar), acurácia (limiar 0,5) e F1-Score (média harmônica de precisão e revocação). Aleatoriedade controlada pela semente 42 em numpy, torch e sklearn.

VI. RESULTADOS E DISCUSSÃO

A. Métricas de Desempenho

A Tabela III apresenta os resultados quantitativos. O ANFIS supera o MLP em todas as métricas: AUC-ROC (+0,011), Acurácia (+2,7 p.p.), F1 (+3,4 p.p.).

Modelo	Parâmetros	Treino (s)	Acurácia	F1-Score	AUC-ROC
ANFIS	228	14,9	84,2%	85,9%	0,912
MLP	2.881	4,8	81,5%	82,5%	0,901

TABELA III. Resultados comparativos — Heart Failure, split 80/20.

Eficiência paramétrica: 228 vs. 2.881 parâmetros (13× menos), reduzindo o risco de overfitting. Custo: treinamento ~3× mais lento (14,9 s vs. 4,8 s), aceitável para diagnóstico offline.

B. Funções de Pertinência Aprendidas

A Fig. 1 mostra as MFs Gaussianas pós-treinamento para as 5 features numéricas. Os centros revelam limiares clinicamente coerentes: em **Age**, as três MFs separam jovens (~40 anos), meia-idade (~55) e idosos (~65); em **MaxHR**, a MF "baixa" concentra-se em ~120 bpm; em **Oldpeak**, a MF "elevado" captura depressões acima de ~1,5 mm, alinhado ao critério diagnóstico de isquemia.




Fig. 1. MFs Gaussianas aprendidas pelo ANFIS após treinamento (features numéricas) e MFs triangulares de saída (fixas).

C. Matrizes de Confusão




Fig. 2. Matrizes de confusão no conjunto de teste: ANFIS (esq.) e MLP (dir.).

O ANFIS produz 18 falsos negativos a menos que o MLP no conjunto de teste. Em contexto clínico—onde doença não detectada é o erro mais custoso—isso representa uma vantagem diagnóstica significativa.

D. Regras Linguísticas Extraídas

A Tabela IV lista as top-10 regras por força de disparo média. Dois padrões emergem consistentemente:

- **Alto risco:** CPT=ASY, MaxHR baixa, Ang=Y, OP elevado, ST=Flat — marcadores estabelecidos de isquemia coronariana [4].
- **Baixo risco:** CPT=ATA, MaxHR alta, Ang=N, OP normal, ST=Up — compatível com resposta fisiológica

normal ao esforço.

#	Antecedente (abreviado)	Risco
1	Age=jovem, CPT=ATA, MaxHR=alta, Ang=N, OP=normal, ST=Up	BAIXO
2	Age=jovem, CPT=ASY, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
3	Age=idoso, CPT=ASY, ECG=ST, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
4	Age=jovem, CPT=ATA, RBP=elevado, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
5	Age=jovem, CPT=ATA, RBP=otimo, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
6	Age=jovem, Sex=F, CPT=ATA, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
7	Age=idoso, CPT=ASY, ECG=LVH, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
8	Age=jovem, CPT=NAP, MaxHR=alta, Ang=N, OP=normal, ST=Up	BAIXO
9	Age=jovem, CPT=ASY, FBS=1, MaxHR=baixa, Ang=N, OP=normal, ST=Flat	ALTO
10	Age=jovem, CPT=ASY, RBP=elevado, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO

TABELA IV. Top-10 regras ANFIS por força de disparo média. CPT=ChestPainType, RBP=RestingBP, Ang=ExerciseAngina, OP=Oldpeak, FBS=FastingBS.

VII. CONCLUSÃO

O ANFIS com fuzzificação mista e pool de regras por K-Means atinge AUC-ROC 0,912 com apenas 228 parâmetros—13× menos que o MLP—e produz 10 regras linguísticas auditáveis alinhadas à literatura clínica.

A interpretabilidade genuína—centros Gaussianos com significado físico, consequentes TS por regra, e regras SE-ENTÃO inteligíveis—diferencia o ANFIS de métodos post-hoc como SHAP, onde a explicação é gerada após o fato.

Trabalho futuro: Validar em datasets maiores e multi-classe; incorporar conhecimento de especialistas na inicialização das MFs; comparar com ANFIS clássico [2] e sistemas Mamdani; investigar definições formais de MFs para variáveis categóricas.

. REFERÊNCIAS

- [1] A. Holzinger et al., "Causability and explainability of artificial intelligence in medicine," *WIREs DMKD*, vol. 9, no. 4, 2019.
- [2] J.-S. R. Jang, "ANFIS: Adaptive-network-based fuzzy inference system," *IEEE Trans. SMC*, vol. 23, no. 3, pp.

665–685, 1993.

[3] F. Fedesoriano, "Heart Failure Prediction Dataset," Kaggle, 2021.

[4] R. A. Gibbons et al., "ACC/AHA 2002 Guideline Update for Exercise Testing," *J. Am. Coll. Cardiol.*, vol. 40, no. 8, 2002.

[5] L. A. Zadeh, "Fuzzy sets," *Inf. Control*, vol. 8, no. 3, pp. 338–353, 1965.

[6] J. C. Bezdek et al., "FCM: The fuzzy c-means clustering algorithm," *Comput. Geosci.*, vol. 10, pp. 191–203, 1984.