

Sistemas Neuro-Fuzzy para Classificação de Risco Cardíaco: Comparação entre ANFIS e MLP com Foco em Interpretabilidade

Victor M. Bertini

Faculdade de Engenharia Elétrica e de Computação (FEEC) — Universidade Estadual de Campinas (Unicamp)
Campinas, SP, Brasil — RA: 194761 — victor.m.bertini@gmail.com

Abstract—Este trabalho investiga o tradeoff entre acurácia preditiva e interpretabilidade em modelos de aprendizado de máquina aplicados a classificação de risco de doença cardíaca. Propomos e avaliamos um sistema ANFIS (Adaptive Neuro-Fuzzy Inference System) de Takagi-Sugeno com fuzzificação mista—funções Gaussianas para variáveis numéricas e codificação one-hot suavizada para variáveis categóricas—cujo pool de regras é gerado por agrupamento K-Means. Os experimentos no Heart Failure Prediction Dataset (918 pacientes, 11 features) mostram que o ANFIS atinge AUC-ROC de 0,912, acurácia de 84,2% e F1-Score de 85,9%, superando o MLP baseline (AUC 0,901; acurácia 81,5%; F1 82,5%) com apenas 228 parâmetros treináveis frente a 2.881 do MLP. Além do desempenho superior, o ANFIS produz 10 regras linguísticas SE-ENTÃO auditáveis, revelando padrões clínicos alinhados à literatura médica sobre isquemia cardíaca.

Keywords—ANFIS; Lógica Fuzzy; Redes Neurais; Doença Cardíaca; Interpretabilidade; Takagi-Sugeno; K-Means

I. INTRODUÇÃO

Sistemas de apoio a decisão clínica baseados em aprendizado de máquina atingem alta acurácia em tarefas de diagnóstico, porém frequentemente operam como caixas-pretas, fornecendo previsões sem justificativa inteligível [1]. No contexto médico, a rastreabilidade das decisões é tanto um requisito ético quanto regulatório: um especialista precisa entender *por que* um paciente foi classificado como alto risco para validar ou contestar a recomendação.

Sistemas Neuro-Fuzzy—em particular o ANFIS—combinam a capacidade de aprendizado de redes neurais com a interpretabilidade de sistemas de inferência fuzzy [2]. Regras linguísticas do tipo SE *antecedente* ENTÃO *consequente* permitem que clínicos e auditores inspecionem os critérios decisórios sem exigir expertise em aprendizado de máquina.

Este trabalho apresenta: (i) uma arquitetura ANFIS com fuzzificação mista para lidar com features numéricas e categóricas no mesmo pipeline; (ii) um método de geração de pool de regras por K-Means que escala para datasets com múltiplas variáveis categóricas; e (iii) uma comparação quantitativa com MLP no Heart Failure Prediction Dataset [3], demonstrando que o ANFIS supera o MLP em todas as métricas com 13× menos parâmetros.

II. DATASET E PRÉ-PROCESSAMENTO

A. Heart Failure Prediction Dataset

O dataset combina registros de cinco fontes clínicas distintas, totalizando 918 pacientes adultos. A variável alvo, **HeartDisease**, é binária (0 = saudável, 1 = doença cardiovascular), com prevalência de aproximadamente 55% de positivos. A divisão treino/teste segue a proporção 80/20 com estratificação por classe.

As 11 features compreendem 5 variáveis numéricas e 6 categóricas:

Feature	Tipo	Descrição
Age	Numérica	Idade (anos)
RestingBP	Numérica	Pressão arterial em repouso (mmHg)
Cholesterol	Numérica	Colesterol sérico (mg/dL)
MaxHR	Numérica	Frequência cardíaca máxima (bpm)
Oldpeak	Numérica	Depressão do segmento ST (mm)
Sex	Categórica	M / F
ChestPainType	Categórica	ATA / NAP / ASY / TA
FastingBS	Categórica	Glicemia em jejum > 120 mg/dL (0/1)
RestingECG	Categórica	Normal / ST / LVH
ExerciseAngina	Categórica	Y / N
ST_Slope	Categórica	Up / Flat / Down

TABELA I. Features do dataset.

B. Pré-Processamento

Valores zerados em **RestingBP** e **Cholesterol** (cl clinicamente impossíveis) são substituídos pela mediana das entradas não-nulas. Features categóricas são codificadas como inteiros via `pd.Categorical.codes`. A normalização é realizada pelo **PartialScaler**: z-score

exclusivamente nas 5 features numéricas, preservando os códigos inteiros das categóricas. Esta distinção é fundamental para a *MixedFuzzyLayer*, que trata os dois grupos com mecanismos de fuzzificação distintos.

III. ARQUITETURA ANFIS

O modelo ANFIS proposto segue o paradigma Takagi-Sugeno de ordem zero e é composto por três camadas treináveis encadeadas. O fluxo de dados segue a sequência:

$$X [B,11] \rightarrow \text{MixedFuzzyLayer} \rightarrow [B,11,M] \rightarrow \\ \text{ClusterRuleLayer} \rightarrow [B,R] \rightarrow \text{DefuzzyLayer} \rightarrow [B,1] \rightarrow \\ \text{sigmoid} \rightarrow P(\text{doença})$$

onde B é o tamanho do batch, M o número de funções de pertinência por feature numérica, e R o número de regras no pool.

A. MixedFuzzyLayer

Esta camada fuzzifica cada feature de acordo com seu tipo: Features numéricas: Funções de Pertinência (MFs) Gaussianas treináveis com parâmetros de centro c e variância σ :

$$\mu(x) = \exp(-1/2 \cdot ((x - c) / \sigma)^2)$$

Os parâmetros c e σ são otimizados por retropropagação. As variâncias são clampeadas em $\sigma \geq 10$ para evitar instabilidade numérica e inicializadas com $\sigma = |N(0,1)| + 0,1$ para garantir positividade.

Features categóricas: Codificação one-hot suavizada sem parâmetros treináveis:

$$\mu_j(\text{cat}) = 0,95 \text{ se } j = \text{cat}, \text{ senão } 0,05/(n_{\text{cats}} - 1)$$

Este esquema preserva a estrutura discreta da variável enquanto fornece um sinal de gradiente não-nulo para as demais posições, evitando o colapso de regras durante o treinamento.

B. ClusterRuleLayer

Calcula a força de disparo de cada regra k por T-norma produto:

$$w_k = \prod_i \mu_{i, \text{combo}[k,i]}(x_i)$$

onde $\text{combo}[k,i]$ é o índice da MF da regra k na feature i . A tabela de combinações rule_idx é armazenada como register_buffer , garantindo migração automática para GPU. A camada não possui parâmetros treináveis: seu único papel é estrutural.

C. DefuzzyLayer

Implementa defuzzificação Takagi-Sugeno normalizada:

$$w_{\blacksquare k} = w_k / (\sum_j w_j + \epsilon) \\ \blacksquare = \sum_k w_{\blacksquare k} \cdot c_k$$

Os consequentes c_k são os pesos de uma $nn.Linear(R \rightarrow 1)$ otimizada por retropropagação. A normalização garante que a saída permaneça na escala correta independentemente do número de regras que disparam simultaneamente, preservando a interpretação TS dos consequentes.

D. Função de Perda

A função de perda combina entropia cruzada binária com uma penalidade de separação de centros de MFs:

$$L = BCE(\sigma(\blacksquare), y) + \lambda \cdot \sum_{i < j} \text{relu}(\sigma_i + \sigma_j - |c_i - c_j|)$$

O termo de penalidade ($\lambda=0,1$) é zero quando os centros de MFs adjacentes estão afastados por pelo menos $\sigma_i + \sigma_j$, e cresce linearmente caso contrário. Isso evita que uma MF estreita fique inteiramente contida dentro de uma MF larga, o que tornaria a partição linguística incoerente.

IV. GERAÇÃO DO POOL DE REGRAS VIA K-MEANS

O número de combinações possíveis de antecedentes cresce exponencialmente com o número de features: $n_{\text{rules}} = M^{n_{\text{inputs}}}$. Para 11 features com $M=3$, isso resultaria em 177.147 regras—inviável. Para mitigar esta explosão combinatória, adotamos o seguinte pipeline de geração de regras antes do treinamento:

Passo 1 — Picos percentílicos (artifício de mapeamento):

Para cada feature numérica, calculamos n_{mfs} percentis uniformemente espaçados da distribuição de treino (P25, P50, P75 para $n_{\text{mfs}}=3$). Estes percentis servem como "picos" de MFs triangulares auxiliares para o mapeamento—não são as MFs Gaussianas do ANFIS.

Passo 2 — K-Means clustering: Aplicamos K-Means com 200 clusters no espaço de features de treino, identificando as regiões de maior densidade.

Passo 3 — Mapeamento dominante: Para cada centro de cluster, determinamos a MF dominante em cada feature: numérica $\rightarrow \text{argmax}$ da MF triangular nos picos; categórica $\rightarrow \text{round}(\text{centro}) \rightarrow \text{código inteiro}$.

Passo 4 — Deduplicação: Clusters com o mesmo vetor de MFs dominantes são colapsados em uma única regra. Dos 200 clusters, resultaram 197 combinações únicas nesta execução.

Passo 5 — Inicialização: Os centros Gaussianos do ANFIS são inicializados nos percentis dos centros

K-Means por feature, fornecendo um ponto de partida informado para o treinamento end-to-end.

V. CONFIGURAÇÃO EXPERIMENTAL

Os hiperparâmetros foram fixados conforme a Tabela II. Ambos os modelos são treinados com otimizador Adam, scheduler de learning rate por plateau e early stopping com paciência de 20 épocas.

Parâmetro	ANFIS	MLP
Épocas	200	200
Batch size	32	32
Learning rate	1×10^{-3}	1×10^{-3}
Arquitetura	3 MFs, 197 regras	[64, 32]
Parâmetros	228	2.881
Regularização	Sep. penalty $\lambda=0,1$	—
Semente	42	42

TABELA II. Hiperparâmetros experimentais.

As métricas de avaliação são calculadas no conjunto de teste (20% dos dados): AUC-ROC (insensível ao limiar), acurácia (limiar 0,5) e F1-Score (média harmônica de precisão e revocação, preferível para classes desbalanceadas). A aleatoriedade é controlada pela semente 42 em numpy, torch e sklearn.

VI. RESULTADOS E DISCUSSÃO

A. Métricas de Desempenho

A Tabela III apresenta os resultados quantitativos. O ANFIS supera o MLP em todas as três métricas, com destaque para a AUC-ROC ($\Delta=+0,011$) e o F1-Score ($\Delta=+3,4$ p.p.), indicando melhor capacidade de separação entre classes positiva e negativa.

Modelo	Parâmetros	Treino (s)	Acurácia	F1-Score	AUC-ROC
ANFIS	228	14,9	84,2%	85,9%	0,912
MLP	2.881	4,8	81,5%	82,5%	0,901

TABELA III. Resultados comparativos (Heart Failure, split 80/20).

A eficiência paramétrica é notável: o ANFIS usa 13× menos parâmetros que o MLP (228 vs. 2.881), o que reduz o risco de overfitting e facilita inspeção e auditoria do modelo. O custo é um treinamento aproximadamente 3× mais lento (14,9 s vs. 4,8 s), aceitável em aplicações de diagnóstico offline.

B. Funções de Pertinência Aprendidas

A Fig. 1 mostra as MFs Gaussianas após o treinamento para as 5 features numéricas, além das MFs triangulares de saída (fixas). Os centros aprendidos revelam limiares clinicamente coerentes: em **Age**, as três MFs separam jovens (~40 anos), meia-idade (~55 anos) e idosos (~65 anos); em **MaxHR**, a MF "baixa" concentra-se em ~120 bpm, abaixo da frequência esperada de resposta ao esforço. Em **Oldpeak**, a MF "elevado" captura depressões do segmento ST acima de ~1,5 mm, alinhado ao critério diagnóstico de isquemia.




Fig. 1. Funções de Pertinência Gaussianas aprendidas pelo ANFIS após 200 épocas (features numéricas) e MFs triangulares de saída (hardcoded).

C. Matrizes de Confusão

		Matriz de Confusão	
		ANFIS	MLP
Real	Sem doença (0)	67	10
	Doença cardíaca (1)	19	88
		Previsto (acurácia: 84,2%)	Previsto (acurácia: 81,5%)

Fig. 2. Matrizes de confusão no conjunto de teste: ANFIS (esq.) e MLP (dir.).

O ANFIS apresenta 18 falsos negativos (FN) a menos que o MLP no conjunto de teste, o que em contexto clínico (risco de doença não detectada) representa uma vantagem diagnóstica significativa. A redução em FN contribui para o maior F1-Score observado.

D. Regras Linguísticas Extraídas

As 10 regras com maior força de disparo média sobre o conjunto de treino são apresentadas na Tabela IV. Dois padrões emergem consistentemente:

- Alto risco:** ChestPainType=ASY (assintomático), MaxHR baixa, ExerciseAngina=Y, Oldpeak elevado, ST_Slope=Flat. Estes são marcadores estabelecidos de isquemia coronariana [4].
- Baixo risco:** ChestPainType=ATA (atípica), MaxHR alta, ExerciseAngina=N, Oldpeak normal, ST_Slope=Up.

Compatível com resposta fisiológica normal ao esforço.

#	Antecedente (abrev.)	Risco
1	Age=jovem, CPT=ATA, MaxHR=alta, Ang=N, OP=normal, ST=Up	BAIXO
2	Age=jovem, CPT=ASY, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
3	Age=idoso, CPT=ASY, ECG=ST, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
4	Age=jovem, CPT=ATA, RBP=elevado, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
5	Age=jovem, CPT=ATA, RBP=otimo, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
6	Age=jovem, Sex=F, CPT=ATA, MaxHR=baixa, Ang=N, OP=normal, ST=Up	BAIXO
7	Age=idoso, CPT=ASY, ECG=LVH, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO
8	Age=jovem, CPT=NAP, MaxHR=alta, Ang=N, OP=normal, ST=Up	BAIXO
9	Age=jovem, CPT=ASY, FBS=1, MaxHR=baixa, Ang=N, OP=normal, ST=Flat	ALTO
10	Age=jovem, CPT=ASY, RBP=elevado, MaxHR=baixa, Ang=Y, OP=elevado, ST=Flat	ALTO

TABELA IV. Top-10 regras ANFIS por força de disparo média.
CPT=ChestPainType, RBP=RestingBP, Ang=ExerciseAngina,
OP=Oldpeak, FBS=FastingBS.

VII. CONCLUSÃO

Este trabalho demonstrou que o ANFIS com fuzzificação mista e pool de regras gerado por K-Means é uma alternativa viável e superior ao MLP para classificação de risco cardíaco, atingindo AUC-ROC de 0,912 com apenas 228 parâmetros treináveis—13× menos que o MLP—e produzindo 10 regras linguísticas auditáveis alinhadas à literatura clínica.

A interpretabilidade genuína obtida—centros Gaussianos com significado físico, consequentes TS por regra, e regras SE-ENTÃO inteligíveis—diferencia o ANFIS de métodos post-hoc como SHAP, onde a explicação é gerada após o fato e não faz parte do processo decisório.

Limitações e trabalho futuro: O modelo foi testado em um único dataset (n=918). Trabalhos futuros devem: (i) validar em datasets maiores e multi-classe; (ii) incorporar conhecimento de especialistas na inicialização das MFs; (iii) comparar com ANFIS clássico (Jang, 1993) e sistemas fuzzy Mamdani; e (iv) investigar métodos formais de definição de MFs para variáveis categóricas.

. REFERÊNCIAS

[1] A. Holzinger, G. Langs, H. Denk, K. Zatloukal, and H. Müller, "Causability and explainability of artificial

intelligence in medicine," *WIREs Data Mining Knowl. Discov.*, vol. 9, no. 4, 2019.

[2] J.-S. R. Jang, "ANFIS: Adaptive-network-based fuzzy inference system," *IEEE Trans. Syst. Man Cybern.*, vol. 23, no. 3, pp. 665–685, 1993.

[3] F. Fedesoriano, "Heart Failure Prediction Dataset," Kaggle, 2021. [Online]. Available: <https://www.kaggle.com/fedesoriano/heart-failure-prediction>

[4] R. A. Gibbons et al., "ACC/AHA 2002 Guideline Update for Exercise Testing," *J. Am. Coll. Cardiol.*, vol. 40, no. 8, pp. 1531–1540, 2002.

[5] J. C. Bezdek, R. Ehrlich, and W. Full, "FCM: The fuzzy c-means clustering algorithm," *Comput. Geosci.*, vol. 10, no. 2–3, pp. 191–203, 1984.

[6] L. A. Zadeh, "Fuzzy sets," *Inf. Control*, vol. 8, no. 3, pp. 338–353, 1965.